

稀疏 SBM 的譜信息與局部似然比檢驗

Degree 保留、LOO 還原與 L^2 壓縮的統計意義

研究討論整理稿 v0.1

2026 年 10 月 9 日

摘要

本文整理一條從正則化譜信息還原 SBM 區塊連邊計數、再進行局部似然比檢驗的路線。對固定社區數、正元素滿秩連接矩陣，以及平均度與 d_n 同階、 $d_n \rightarrow \infty$ 、 $d_n = o(\log n)$ 的模型，考慮保留原始 degree 及一次全圖正則化矩陣的前 k 個信號特徵對。利用 eigen-equation 可直接取得節點連接向量對譜基底的點積；以估計社區中心反解後，得到區塊連邊計數及 plug-in LLR。證明先在獨立 leave-one-out (LOO) 訓練圖上建立 LLR 的大偏差等價，再以截斷譜行能量控制全圖與 LOO 的差異。得到的結論是局部分類錯誤的領先指數與原始資料 oracle LRT 相同。最後說明：SVD 的 L^2 目標用於估計可容納充分統計量的子空間，而對數概率權重在解碼後施加，兩者並不衝突。

本稿的結論與範圍。本文記錄本次討論中的推導；正則化集中工具引用文獻 [1]，全圖截斷能量與 LOO 橋接則在文中展開。結論是 $R_{\text{spec}} = \exp\{-d_n I + o(d_n)\}$ ，不等同於 $R_{\text{spec}}/R_{\text{oracle}} \rightarrow 1$ ，也不宣稱整個參數實驗的 Fisher information 或 Le Cam 意義下的無損。平均度有界、社區數增長、連接矩陣隨 n 退化及零連接概率不在本稿定理範圍。

目錄

1	模型、保存的統計量與主要結論	3
1.1	SBM 與局部檢驗	3
1.2	Regularization 與譜信息	3
1.3	錯誤指數	3
2	只用保存資料的算法	4
2.1	初始社區與社區譜中心	4
2.2	反解區塊連邊計數	4
2.3	連接概率估計與 plug-in LLR	4
3	正則化集中、初始一致性與參數估計	5
3.1	適用於兩倍平均 degree 門檻的集中界	5
3.2	信號間隔及秩 k 重建	6
3.3	社區內權重與中心的一致性	6
3.4	只從譜資料估計連接概率	7
4	獨立 LOO 投影與 LLR 的大偏差等價	7
4.1	訓練圖及有限範圍的譜坐標	7
4.2	LLR 誤差的條件矩母函數	8
5	全圖譜向量的截斷行能量	8
5.1	好事件與 LOO 權重擾動	8
5.2	同一門檻下的能量遞推	9
5.3	獨立 innovation 的 Bennett 尾界	10
6	由全圖特徵橋接到獨立 LOO 特徵	11
6.1	中心逆矩陣消去譜旋轉	12
7	Oracle Chernoff 指數與主要定理的完成	13
8	為何 L^2 譜壓縮可以保留 LLR	14
8.1	觀測到的 LLR 對連邊數是線性的	14
8.2	母體譜空間保留了哪些方向	14
8.3	對數沒有把 LRT 帶出這個空間	15
8.4	可逆座標變換，以及 k -means 的差別	15
8.5	從母體恆等式到樣本譜信息的界線	16
9	結果的邊界與後續可研究問題	17
	編譯說明	17

1 模型、保存的統計量與主要結論

1.1 SBM 與局部檢驗

令 $A \in \{0, 1\}^{n \times n}$ 為無自環、無向圖的 adjacency matrix。給定社區標籤 $z = (z_1, \dots, z_n)$ ，上三角元素獨立，且

$$A_{ij} \mid z \sim \text{Bernoulli}(B_{n, z_i z_j}), \quad B_n = \rho_n C, \quad \rho_n = \frac{d_n}{n}. \quad (1.1)$$

假設 k 固定， $C \in \mathbb{R}^{k \times k}$ 固定、對稱、滿秩，且

$$0 < c_- \leq C_{ab} \leq c_+ < \infty, \quad \pi_{a,n} := \frac{n_a}{n} \longrightarrow \pi_a > 0.$$

另假設

$$d_n \longrightarrow \infty, \quad d_n = o(\log n). \quad (1.2)$$

以下簡寫 $d = d_n$ 、 $B = B_n$ 。常數 $K, c > 0$ 可依賴 $C, k, \min_a \pi_a$ 及固定的概率階數 r ，不依賴 n ；不同公式中的常數可不同。

令 $Z \in \{0, 1\}^{n \times k}$ 為社區指示矩陣。區分

$$P = \mathbb{E}[A \mid z], \quad P_0 = \rho_n Z C Z^\top, \quad P = P_0 - \text{diag}(\rho_n C_{z_i z_i}). \quad (1.3)$$

因此 $\|P - P_0\|_{\text{op}} = O(\rho_n)$ ； P_0 才是精確的秩 k 比較矩陣。

局部二元檢驗固定其餘標籤 z_{-i} ，比較 $H_a: z_i = a$ 與 $H_b: z_i = b$ 。oracle 可使用 z_{-i}, B 及全部原始連邊 $A_{i, -i}$ 。即使研究等分社區，這個局部比較也允許候選模型的社區人數相差 1；不把精確總人數當成決定最後一個標籤的額外信息。未知標籤算法的輸出按共同社區排列評估，排列以其餘節點對齊；對齊只用於定義損失，不是算法的輸入。

1.2 Regularization 與譜信息

記

$$D_i = \sum_j A_{ij}, \quad \bar{D} = \frac{1}{n} \sum_i D_i, \quad \tau = 2\bar{D},$$

$$w_i = \min\{1, \tau/D_i\}, \quad W = \text{diag}(w_1, \dots, w_n), \quad M = W A W. \quad (1.4)$$

$D_i = 0$ 時取 $w_i = 1$ 。若全圖沒有邊，算法任意輸出；這個事件的概率在本模型下為 $\exp\{-\Theta(nd)\}$ 。

令 $MU = U\Lambda$ 、 $U^\top U = I_k$ ，取 M 的絕對值最大的 k 個特徵值及其特徵向量。一般對稱滿秩 C 可以有負特徵值，不能一律只取代數最大的 k 個。保存的資料為

$$S(A) = (D, U, \Lambda), \quad D = (D_1, \dots, D_n)^\top.$$

給定 D ，即可重新計算 W 。

1.3 錯誤指數

對 $a \neq b$ ，定義

$$I_{ab} = \max_{0 \leq s \leq 1} \sum_{c=1}^k \pi_c \{(1-s)C_{ac} + sC_{bc} - C_{ac}^{1-s} C_{bc}^s\}. \quad (1.5)$$

滿秩保證各行不同，所以 $I_{ab} > 0$ 。

定理 1.1 (Degree 加單次全圖譜信息的局部 LRT 指數)。在上述假設下，第 2 節的算法只使用 $\mathcal{S}(A)$ 。對任一固定節點及候選社區 a, b ，其 pairwise 分數檢驗在等先驗下的風險滿足

$$R_{\text{spec},ab} = \exp\{-dI_{ab} + o(d)\}, \quad \frac{-\log R_{\text{spec},ab}}{-\log R_{\text{oracle},ab}} \rightarrow 1. \quad (1.6)$$

固定正先驗只改變 $O(1)$ 的閾值，不改變此結論。固定 k 的多社區分類可用有限個 pairwise 比較；相應整體平均錯誤的領先指數由最難區分的一對社區控制。

主要的強誤差結論為：對每個固定 $\varepsilon > 0$ ，在 H_a, H_b 任一假設下，

$$\limsup_{n \rightarrow \infty} \frac{1}{d} \log \mathbb{P}\left(|\hat{L}_i^{ab} - L_i^{ab}| > \varepsilon d\right) = -\infty. \quad (1.7)$$

這是速度 d 的大偏差等價，嚴格強於普通的 $o_P(d)$ 。

2 只用保存資料的算法

2.1 初始社區與社區譜中心

對 $\sqrt{n} WU$ 的行做固定近似比的 k -means（全局最優亦可），得到初始指示矩陣 $\hat{Z}$ 。令 $\hat{z}_a$ 為其第 a 列，並定義

$$\hat{n}_a = \mathbf{1}^\top \hat{z}_a, \quad \hat{\pi}_a = \hat{n}_a/n, \quad \hat{H} = \text{diag}(\hat{n}_1, \dots, \hat{n}_k)^{-1} \hat{Z}^\top WU. \quad (2.1)$$

$\hat{H}$ 的第 a 行是估計社區 a 的平均譜特徵。這一步只要求初始誤分比例 $o(1)$ 。

2.2 反解區塊連邊計數

由 eigen-equation 有精確恆等式

$$AWU = W^{-1}U\Lambda. \quad (2.2)$$

右側可由 $\mathcal{S}(A)$ 計算，提供每個節點連接向量對譜基底的點積。令

$$\hat{N}^{(0)} = W^{-1}U\Lambda\hat{H}^{-1}, \quad \hat{N} = \hat{N}^{(0)} + (D - \hat{N}^{(0)}\mathbf{1}_k)\hat{\pi}^\top. \quad (2.3)$$

則 $\hat{N}\mathbf{1}_k = D$ 精確成立。若理想基底滿足 $WU = ZH$ ，便有

$$W^{-1}U\Lambda = AWU = AZH, \quad W^{-1}U\Lambda H^{-1} = AZ.$$

而 $(AZ)_{ic}$ 正是節點 i 連到 block c 的邊數。

2.3 連接概率估計與 plug-in LLR

令 $M_k = U\Lambda U^\top$ 、 $w = (w_j)_{j=1}^n$ ，取

$$\hat{B}_{ab} = \frac{\hat{z}_a^\top M_k \hat{z}_b}{(\hat{z}_a^\top w)(\hat{z}_b^\top w)}. \quad (2.4)$$

分母補回社區平均減權。對角的無自環修正是漸近可忽略的；本式不需另外估計 ρ_n 。

記 $\hat{m}_c^{(-i)} = \hat{n}_c - \mathbf{1}\{\hat{z}_i = c\}$ ，定義

$$\hat{S}_i(a) = \sum_{c=1}^k \left\{ \hat{N}_{ic} \log \hat{B}_{ac} + (\hat{m}_c^{(-i)} - \hat{N}_{ic}) \log(1 - \hat{B}_{ac}) \right\}. \quad (2.5)$$

輸出使分數最大的社區；pairwise 分數為 $\hat{L}_i^{ab} = \hat{S}_i(a) - \hat{S}_i(b)$ 。 $\hat{N}_{ic}$ 可以非整數或帶符號；式 (2.5) 是重建的線性 likelihood score，不宜稱它是某組實際 Bernoulli 樣本的概率。若某估計社區為空、 $\hat{H}$ 不可逆或 $\hat{B} \notin (0, 1)^{k \times k}$ ，任意定義輸出即可；以下好事件上，這些情況最終不會發生。

實際輸入。 算法中所有量均由 D, U, Λ 得到。LOO 特徵和坐標截斷只在證明中使用；實際算法不需要保存額外的 LOO 投影。需要保留的是逐節點的譜行波動，不能在反解前把每個初始社區內的行全部平均掉。

3 正則化集中、初始一致性與參數估計

3.1 適用於兩倍平均 degree 門檻的集中界

引理 3.1 (中心化加權噪音)。對任意固定 $r > 0$ ，存在 K_r ，使

$$\mathbb{P}\left\{\|W(A - P)W\|_{\text{op}} > K_r \sqrt{d}\right\} = O(n^{-r}).$$

相同結論適用於刪去固定數目節點後、重新計算權重的訓練圖。

證明. 設 $d_{\max} = n \max_{ij} P_{ij} \asymp d$ ，並引入只供證明的權重

$$t_j = \min\{1, 4d_{\max}/D_j\}, \quad T = \text{diag}(t_j).$$

它只修改 $S = \{j : D_j > 4d_{\max}\}$ 的關聯邊。以概率 $1 - e^{-cn}$ ，有 $|S| \leq 10n/d_{\max}$ 。事實上，若存在大小 $s = \lceil 10n/d_{\max} \rceil$ 的此類子集，其 degree 總和大於 $4sd_{\max}$ ，期望不超過 $sd_{\max}$ 。degree 總和是係數為 1 或 2 的獨立 Bernoulli 和，Bernstein 給 $e^{-csd_{\max}}$ ；子集數的對數 $O(s \log(en/s)) = O(n \log d/d) = o(n)$ ，可由 union bound 吸收。

TAT 的最大加權 degree 不超過 $4d_{\max}$ 。Le-Levina-Vershynin 的正則化集中定理 [1, Theorem 2.1] 允許資料依賴的這類減權，因此

$$\|TAT - P\|_{\text{op}} \leq K_r \sqrt{d_{\max}}$$

以概率 $1 - O(n^{-r})$ 成立。每個 P 行的 Euclidean norm 至多 $d_{\max}/\sqrt{n}$ ，所以

$$\|(I - T)P\|_{\text{op}} \leq \|(I - T)P\|_{\text{F}} \leq d_{\max} \sqrt{|S|/n} = O(\sqrt{d}).$$

由 $P - TPT = (I - T)P + TP(I - T)$ ，得到 $\|T(A - P)T\|_{\text{op}} = O(\sqrt{d})$ 。

另一方面， $\bar{D} \leq 2d_{\max}$ 的失敗概率為 e^{-cnd} 。在此事件上 $W \leq T$ 逐項成立，令 $R = WT^{-1}$ ，則 $\|R\|_{\text{op}} \leq 1$ ，並且

$$W(A - P)W = RT(A - P)TR.$$

左右乘收縮矩陣即得結論。這一步處理了 $2\bar{D}$ 可能壓縮整個高平均 degree 社區、而非只壓縮極少節點的情形。□

3.2 信號間隔及秩 k 重建

記 $Q = Z^\top W^2 Z$ 。每個社區至少一半節點滿足 $D_j \leq 2n\bar{D}/n_a$ ，否則其 degree 總和超過全圖總和。這些節點滿足 $w_j \geq n_a/n$ ，因此

$$Q_{aa} \geq \frac{n_a}{2} \left(\frac{n_a}{n} \right)^2 \geq cn.$$

對 $\bar{D} > 0$ ，這是確定性結論。因 C 滿秩，

$$\sigma_k(WP_0W) \geq cd. \quad (3.1)$$

引理 3.1 和 (1.3) 給 $\|M - WP_0W\|_{\text{op}} \leq K_r \sqrt{d}$ 。按特徵值絕對值截斷及最佳秩 k 逼近不等式，得到

$$\|M_k - WP_0W\|_{\text{op}} \leq K_r \sqrt{d}. \quad (3.2)$$

這裡 WP_0W 是隨機代數比較矩陣，不是 $\mathbb{E}[M | W]$ 。

母體信號空間的一組正交基為

$$U_0 = WZQ^{-1/2}O, \quad O^\top O = I_k.$$

殘差／子空間擾動界由 (3.1) 給

$$\inf_{O^\top O = I_k} \|U - WZQ^{-1/2}O\|_F = O(d^{-1/2}). \quad (3.3)$$

因 $Q_{aa} \geq cn$ ，母體基底的每行 norm 都不超過 $K/\sqrt{n}$ 。

3.3 社區內權重與中心的一致性

定義有限樣本母體量

$$\kappa_{a,n} = \sum_b \pi_{b,n} C_{ab}, \quad \bar{\kappa}_n = \sum_a \pi_{a,n} \kappa_{a,n}, \quad \gamma_{a,n} = \min\{1, 2\bar{\kappa}_n/\kappa_{a,n}\}.$$

其值均被正的常數上下控制。取 $\delta_n = d^{-1/8}$ 。對壞點集合 $\{j : |D_j - \mathbb{E}D_j| > \delta_n d\}$ ，若至少有 $2m$ 個壞點，其中 $m = \lceil Kn/d \rceil$ ，便能選出 m 個偏差同號的節點。對其 degree 總和用 Bernstein，union bound 的對數上界為

$$-cm\delta_n^2 d + O(m \log(en/m)).$$

因 $\delta_n^2 d = d^{3/4} \gg \log d$ ，壞點比例為 $O(1/d)$ 的失敗概率至多 $\exp\{-cn\delta_n^2\} = o(n^{-r})$ 。全圖平均 degree 亦以更强概率集中。在其餘節點上，cap 函數的比較給 $|w_j - \gamma_{z_j,n}| \leq K\delta_n$ ，因此

$$\frac{1}{n} \sum_j (w_j - \gamma_{z_j,n})^2 = O(\delta_n^2). \quad (3.4)$$

結合 (3.3)，存在正交 O ，使

$$\frac{1}{n} \|\sqrt{n} WU - ZT_{0,n}\|_F^2 = o(1), \quad T_{0,n} = \text{diag}\left(\frac{\gamma_{a,n}}{\sqrt{\pi_{a,n}}}\right) O. \quad (3.5)$$

上述 $o(1)$ 可在失敗概率 $O(n^{-r})$ 的好事件上取為確定性的界。 $T_{0,n}$ 可逆且條件數有界，行中心彼此分離。固定近似比 k -means 的目標值不超過理想中心目標值的固定倍數，因此初始誤分比例為 $o(1)$ ，估計中心在共同排列下亦一致。

3.4 只從譜資料估計連接概率

對真實社區向量 z_a, z_b ，精確地有

$$z_a^\top W P_0 W z_b = \rho_n C_{ab} (z_a^\top w) (z_b^\top w).$$

估計社區只有 $o(n)$ 個錯誤，且 $0 < w_j \leq 1$ ，故每個估計社區的加權組成只有 $o(1)$ 的污染比例，其加權大小仍為 $\Theta(n)$ 。(3.2) 對分子帶來的誤差最多為 $O(n\sqrt{d})$ ，除以 $\Theta(n^2)$ 後是 $O(\rho_n/\sqrt{d})$ 。所以

$$\max_{a,b} \left| \frac{\hat{B}_{ab}}{\rho_n} - C_{ab} \right| = o(1). \quad (3.6)$$

同樣的結論成立於 LOO 訓練圖。

4 獨立 LOO 投影與 LLR 的大偏差等價

4.1 訓練圖及有限範圍的譜坐標

固定節點 i ，令 $J = [n] \setminus \{i\}$ ，用 A_{JJ} 重新計算

$$D_j^{(i)} = D_j - A_{ij}, \quad \tau_i = \frac{2}{n-1} \left(\sum_j D_j - 2D_i \right), \quad w_j^{(i)} = \min\{1, \tau_i/D_j^{(i)}\}.$$

當 $D_j^{(i)} = 0$ 時仍取 $w_j^{(i)} = 1$ 。訓練矩陣為 $M^{(i)} = W^{(i)} A_{JJ} W^{(i)}$ ，其信號特徵向量在第 i 行補零後記為 $U^{(i)} \in \mathbb{R}^{n \times k}$ ，訓練部分記為 $U_J^{(i)} \in \mathbb{R}^{(n-1) \times k}$ 。所有這些量都獨立於 A_{iJ} 。

對固定、足夠大的 R ，令

$$f_t(v) = v \min\{1, t/\|v\|\}, \quad t = R/\sqrt{n}, \quad V^{(i)} = f_t(U^{(i)}), \quad F_j^{(i)} = \sqrt{n} w_j^{(i)} V_j^{(i)}, \quad j \in J.$$

f_t 按行作用，且 $f_t(0) = 0$ 。其 Euclidean 非擴張性與正交等變性為

$$\|f_t(X) - f_t(Y)\|_F \leq \|X - Y\|_F, \quad f_t(XO) = f_t(X)O. \quad (4.1)$$

母體基底的行 norm 不超過 $K/\sqrt{n}$ ；取 R 超過此常數，截斷不增加對母體基底的誤差。對 $F_j^{(i)}$ 的行作初始聚類並取各估計社區的行均值，記所得 $k \times k$ 中心矩陣為 $\hat{T}_i$ ，比例向量為 $\hat{\pi}^{(i)}$ 。第 3 節給出其一致性與一致可逆性。

定義

$$g_j = F_j^{(i)} \hat{T}_i^{-1} + (1 - F_j^{(i)} \hat{T}_i^{-1} \mathbf{1}_k) (\hat{\pi}^{(i)})^\top, \quad (4.2)$$

$$\hat{N}_i^{\text{LOO}} = \sum_{j \in J} A_{ij} g_j. \quad (4.3)$$

在訓練好事件上，社區名字適當對齊後，

$$g_j \mathbf{1}_k = 1, \quad \max_j \|g_j\| \leq K_R, \quad \frac{1}{n} \sum_{j \in J} \|g_j - e_{z_j}^\top\|^2 = o(1). \quad (4.4)$$

LOO 參數估計用訓練圖的未截斷 $M_k^{(i)}$ 及估計社區，仍滿足 (3.6)。

4.2 LLR 誤差的條件矩母函數

真實連邊計數為 $N_{ic} = \sum_{j \in J: z_j = c} A_{ij}$ ， $m_c = |\{j \in J : z_j = c\}|$ 。定義

$$\ell_c^{ab} = \text{logit}(B_{ac}) - \text{logit}(B_{bc}), \quad (4.5)$$

$$\kappa_{ab} = \sum_c m_c \log \frac{1 - B_{ac}}{1 - B_{bc}}, \quad (4.6)$$

$$L_i^{ab} = \kappa_{ab} + \sum_{j \in J} A_{ij} \ell_{z_j}^{ab}. \quad (4.7)$$

LOO plug-in 分數同樣可寫成 $\hat{\kappa}_{ab} + \sum_{j \in J} A_{ij} \hat{\ell}_j^{ab}$ ，其中 $\hat{\ell}_j^{ab}$ 是 g_j 與估計 logit 對比向量的點積。其差記為

$$\Delta_i = b_i + \sum_{j \in J} A_{ij} e_j. \quad (4.8)$$

由正元素假設、(4.4) 與參數一致性，條件於訓練好事件，有確定性界

$$|b_i| = o(d), \quad \max_j |e_j| \leq K_R, \quad \sum_j |e_j| = o(n). \quad (4.9)$$

最後一項由 Cauchy-Schwarz 得到。截距誤差則由 $o(n)$ 個社區人數誤差乘上 $O(\rho_n)$ ，以及 n 個 $o(\rho_n)$ 參數誤差所控制。

對任意固定 $u > 0$ ，條件於訓練圖後 A_{ij} 獨立，且在 H_a, H_b 任一假設下其成功概率不超過 $K\rho_n$ 。因此

$$\begin{aligned} \log \mathbb{E}[e^{u|\Delta_i|} \mid A_{JJ}] &\leq u|b_i| + \sum_{j \in J} p_{hj}(e^{u|e_j|} - 1) \\ &\leq o(d) + K_{R,u}\rho_n \sum_{j \in J} |e_j| = o(d). \end{aligned} \quad (4.10)$$

對固定 $\varepsilon > 0$ ，Markov 給 $\mathbb{P}(|\Delta_i| > \varepsilon d \mid A_{JJ}) \leq e^{-u\varepsilon d + o(d)}$ 。先取 $n \rightarrow \infty$ ，再讓固定 u 任意大。由 (1.2)，訓練失敗概率 $O(n^{-r})$ 滿足 $d^{-1} \log n^{-r} \rightarrow -\infty$ 。故

$$\limsup_{n \rightarrow \infty} \frac{1}{d} \log \mathbb{P}(|\hat{L}_i^{\text{LOO}, ab} - L_i^{ab}| > \varepsilon d) = -\infty. \quad (4.11)$$

這裡不使用 Gaussian 近似；控制的是 Bernoulli 和本身的矩母函數。

5 全圖譜向量的截斷行能量

5.1 好事件與 LOO 權重擾動

固定所需概率階數 r 。令 $\mathcal{E}$ 包含全圖、所有刪去一個節點的圖及需要的刪去兩個節點的圖之平均 degree、中心化加權噪音、信號間隔與權重平均一致性條件。在單圖界取更大的固定階數 (例如 $r+4$)，union bound 給 $\mathbb{P}(\mathcal{E}^c) = O(n^{-r})$ 。條件只依賴圖、真實區塊及譜旋轉不變量，故在真實社區內置換不變。聚類一致性是這些條件的推論，無需把某種 k -means tie-breaking 規則放進事件定義。

對 $j \in J$ ，令

$$(G_i)_{jj} = w_j^{(i)} / w_j - 1,$$

並令其第 i 個對角元為零。注意 $\tau_i - \tau = 2(\bar{D} - 2D_i)/(n - 1)$ 。對 cap 函數比較分母與門檻的變化，得到

$$|(G_i)_{jj}| \leq K \left\{ \frac{A_{ij}}{\max(\tau, D_j)} + \frac{d + D_i}{nd} \right\}, \quad \|G_i\|_{\text{op}} \leq K/d. \quad (5.1)$$

引理 5.1 (作用於全圖基底的 LOO 擾動界)。在 $\mathcal{E}$ 上，存在正交矩陣 O_i ，使

$$\|U - U^{(i)}O_i\|_{\text{F}} \leq K\|U_{i\cdot}\| + K\|G_iU\|_{\text{F}}. \quad (5.2)$$

證明. 按第 i 行分塊，寫

$$M = \begin{pmatrix} 0 & m_i^\top \\ m_i & B_i \end{pmatrix}, \quad U = \begin{pmatrix} u_i \\ U_J \end{pmatrix}.$$

有 $\|m_i\|^2 \leq w_i^2 D_i \leq \tau \cdot \|B_i\|_{\text{op}} \leq \tau$ ，以及 $B_i U_J = U_J \Lambda - m_i u_i$ 。LOO 的下方矩陣為 $(I + G_i)B_i(I + G_i)$ ；本段分塊公式中的 G_i 表示其 $J \times J$ 子矩陣。把它與全圖相減並作用於 U ，第 i 行為 $-u_i \Lambda$ ，其餘行為

$$-m_i u_i + G_i(U_J \Lambda - m_i u_i) + B_i G_i U_J + G_i B_i G_i U_J.$$

其 Frobenius norm 被 $Kd(\|u_i\| + \|G_iU\|_{\text{F}})$ 控制。全圖信號特徵值與 LOO 非信號特徵值相隔 cd 。對補空間上的 Sylvester 方程使用此間隔，再作正交 Procrustes 對齊，即得 (5.2)。關鍵是右側 G_i 乘上同一個全圖 U ，不是不同的 LOO tails。□

5.2 同一門檻下的能量遞推

固定足夠大的 R ，令

$$t = R/\sqrt{n}, \quad V = f_t(U), \quad T_U = U - V, \quad H_R(U) = \sum_j \|U_{j\cdot}\|^2 \mathbf{1}\{\|U_{j\cdot}\| > t\}.$$

則 $\|T_U\|_{\text{F}}^2 \leq H_R(U)$ 。在本節令

$$E = W(A - P)W, \quad \beta_i = w_i \left(\sqrt{D_i} + \frac{Kd}{\sqrt{n}} \right).$$

有 $\beta_i \leq K\sqrt{d}$ ，且 $\|w_i(A_{iJ} - P_{iJ})\|_2 \leq \beta_i$ 。

引理 5.2 (減權擾動的可求和界)。在 $\mathcal{E}$ 上，

$$\frac{\beta_i}{d} \|G_i V\|_{\text{F}} \leq Kt/d, \quad (5.3)$$

$$\sum_i \beta_i^2 \|G_i T_U\|_{\text{F}}^2 \leq K\|T_U\|_{\text{F}}^2. \quad (5.4)$$

證明. 因每行 $\|V_j\| \leq t$ 、 $\|V\|_{\text{F}} \leq \sqrt{k}$ ，式 (5.1) 給

$$\|G_i V\|_{\text{F}} \leq Kt \frac{\sqrt{D_i}}{d} + K \frac{d + D_i}{nd}.$$

乘上 β_i/d ，使用 $w_i D_i \leq Kd$ 、 $D_i \leq n$ ，即得第一式。第二式交換 i, j 的求和順序。對固定 j ，局部項滿足

$$\sum_i \frac{\beta_i^2 A_{ij}}{\max(\tau, D_j)^2} \leq K.$$

其中 degree 部分可直接用

$$\sum_i \frac{w_i^2 D_i A_{ij}}{\max(\tau, D_j)^2} \leq \frac{\tau D_j}{\max(\tau, D_j)^2} \leq 1,$$

而 d^2/n 部分至多 Kd/n 。全局平均度變化的係數可估為

$$\sum_i \frac{w_i^2 (D_i + d^2/n)(d + D_i)^2}{n^2 d^2} \leq K \left(\frac{d}{n} + \frac{d^2}{n^2} \right) \leq K.$$

此處使用 $w_i^2 D_i^3 \leq \tau^2 D_i$ 與 $\sum_i D_i = O(nd)$ 。因此每個 $\|(T_U)_j\|^2$ 的係數都有一致上界。□

定義未旋轉、由訓練圖決定係數的 innovation

$$K_i = (A_{iJ} - P_{iJ})W^{(i)}f_t(U_J^{(i)}). \quad (5.5)$$

從 eigen-equation

$$U = WPWU\Lambda^{-1} + EV\Lambda^{-1} + ET_U\Lambda^{-1}$$

出發，母體項每行 norm 至多 $K/\sqrt{n}$ ，因 $\|P_i\|_2 \leq Kd/\sqrt{n}$ 、 $\|WU\|_{\text{op}} \leq 1$ 、 $\|\Lambda^{-1}\|_{\text{op}} \leq K/d$ 。對 EV 的第 i 行，使用

$$W_{JJ}V_J - W^{(i)}f_t(U_J^{(i)})O_i = W^{(i)}(V_J - f_t(U_J^{(i)})O_i) + (W_{JJ} - W^{(i)})V_J.$$

由 (4.1)、(5.2) 與 $W_{JJ} - W^{(i)} = -W_{JJ}(G_i)_{JJ}$ ，得到

$$\begin{aligned} \|u_i\| &\leq \frac{K}{\sqrt{n}} + \frac{K}{d}\|K_i\| + \frac{K\beta_i}{d}\|u_i\| + \frac{K\beta_i}{d}\|G_i V\|_{\text{F}} \\ &\quad + \frac{K\beta_i}{d}\|G_i T_U\|_{\text{F}} + \frac{K}{d}\|(ET_U)_i\|. \end{aligned} \quad (5.6)$$

O_i 可以依賴被刪行，但此處只使用 $\|K_i O_i\| = \|K_i\|$ ；不對旋轉後的隨機坐標直接使用條件 Bennett。

取 R 足夠大，再取 d 足夠大，baseline 與 self term 分別可被 $t/8$ 和 $\|u_i\|/8$ 控制。對 $\|u_i\| > t$ 的行，按 $\|K_i\|/d$ 是否超過固定倍數的 t 分情況，得到

$$\begin{aligned} \|u_i\|^2 \mathbf{1}\{\|u_i\| > t\} &\leq \frac{K}{d^2}\|K_i\|^2 \mathbf{1}\{\|K_i\| > cdt\} \\ &\quad + \frac{K}{d^2}\|(ET_U)_i\|^2 + \frac{K\beta_i^2}{d^2}\|G_i T_U\|_{\text{F}}^2. \end{aligned} \quad (5.7)$$

求和並使用 $\|E\|_{\text{op}}^2 \leq Kd$ 、引理 5.2，有

$$H_R(U)\mathbf{1}_{\mathcal{E}} \leq \frac{K}{d^2} \sum_i \|K_i\|^2 \mathbf{1}\{\|K_i\| > cdt\} + \frac{K}{d} H_R(U)\mathbf{1}_{\mathcal{E}}. \quad (5.8)$$

兩邊是同一門檻 R ，故最後一項可以吸收。

5.3 獨立 innovation 的 Bennett 尾界

引理 5.3 (截斷譜行能量)。對足夠大的固定 R ，

$$\mathbb{E}[H_R(U)\mathbf{1}_{\mathcal{E}}] \leq KR^2 \exp\{-cd \log R\}. \quad (5.9)$$

常數 K, c 不依賴 R, n ； n 的充分大條件可依賴固定 R 。

證明. 條件於 A_{JJ} ，式 (5.5) 是獨立中心化向量和，每個向量項 norm 至多 t ，每個坐標的方差總和至多

$$K\rho_n\|f_t(U^{(i)})\|_{\mathbb{F}}^2 \leq Kd/n.$$

這些界對任何訓練圖都成立，無需條件化於全圖好事件。對每個坐標使用 Bennett，並對固定 k 個坐標作 union bound。若方差上界記為 $v = Kd/n$ ，其指數為

$$\frac{v}{t^2} h\left(\frac{tx}{v}\right), \quad h(u) = (1+u)\log(1+u) - u.$$

在 $x = cdt$ 時， tx/v 與 R^2 同階，所以指數至少 $cd\log R$ 。同一尾界作二階矩積分，得到

$$\mathbb{E}[\|K_i\|^2 \mathbf{1}\{\|K_i\| > cdt\}] \leq \frac{Kd^2R^2}{n} \exp\{-cd\log R\}.$$

取 (5.8) 的期望，吸收右側能量項即得結論。 $\square$

因 $\mathcal{E}$ 與譜行 norm 在每個真實社區內置換不變，對 $z_i = a$ 的固定節點，

$$\mathbb{E}[\|U_i\|^2 \mathbf{1}\{\sqrt{n}\|U_i\| > R\} \mathbf{1}_{\mathcal{E}}] \leq \frac{1}{n_a} \mathbb{E}[H_R(U) \mathbf{1}_{\mathcal{E}}].$$

Markov 給

$$\mathbb{P}(\sqrt{n}\|U_i\| > R, \mathcal{E}) \leq K \exp\{-cd\log R\}. \quad (5.10)$$

R 可取任意大的固定常數，故局部尾概率的指數常數可超過任意指定值。

6 由全圖特徵橋接到獨立 LOO 特徵

定義可從保存資料算出的全圖特徵

$$q_i = \sqrt{n} w_i^{-1} U_i \Lambda = \sqrt{n} A_i W U,$$

以及僅用於分析的獨立訓練投影

$$r_i = \sqrt{n} A_{iJ} W^{(i)} f_t(U_J^{(i)}).$$

矩陣按需要在第 i 行補零；全圖 $A_{ii} = 0$ 。有精確分解

$$\begin{aligned} q_i O_i^\top - r_i &= \sqrt{n} A_i W (U O_i^\top - U^{(i)}) \\ &\quad + \sqrt{n} A_{iJ} (W_{JJ} - W^{(i)}) f_t(U_J^{(i)}) \\ &\quad + \sqrt{n} A_i W (U^{(i)} - f_t(U^{(i)})). \end{aligned} \quad (6.1)$$

引理 6.1 (全圖與 LOO 投影在速度 d 下接近)。對任意固定 $\varepsilon > 0, H > 0$ ，可選固定的 L, R 足夠大，使對充分大的 n ，

$$\mathbb{P}(\|q_i O_i^\top - r_i\| > \varepsilon d) \leq e^{-Hd} + O(n^{-r}). \quad (6.2)$$

證明. 先限制於 $\mathcal{E} \cap \{D_i \leq Ld, \sqrt{n}\|U_i\| \leq R\}$ 。由 (5.1)、(5.2)，式 (6.1) 前兩項的非尾部分至多 $K_{L,R}\sqrt{d} = o(d)$ 。

第一項的全圖尾部分被

$$B_i^* = K\sqrt{nD_i}\|G_i T_U\|_{\mathbb{F}}$$

控制。在 $D_i \leq Ld$ 上 $w_i \geq c/L$ ，所以

$$\frac{1}{n} \sum_i (B_i^*)^2 \mathbf{1}_{\{D_i \leq Ld\}} \leq K_L H_R(U).$$

用社區內 exchangeability 和引理 5.3，

$$\mathbb{E}[(B_i^*)^2 \mathbf{1}_{\mathcal{E}, D_i \leq Ld}] \leq K_{L,R} e^{-cd \log R}. \quad (6.3)$$

最後一項的 norm 可由

$$C_i^* = \sqrt{n} \sum_{j \in J} A_{ij} \| (U^{(i)} - f_t(U^{(i)}))_j \|$$

控制，因為 $w_j \leq 1$ 。令 $\mathcal{E}^{(i)}$ 為由訓練圖及其 LOO 圖定義的好事件； $\mathcal{E} \subseteq \mathcal{E}^{(i)}$ ，後者獨立於 A_{iJ} 。條件於訓練圖，獨立 Bernoulli 和的二階矩給

$$\mathbb{E}[(C_i^*)^2 \mid A_{JJ}] \leq K(d + d^2) H_R(U^{(i)}).$$

把全圖事件指標放大成訓練可測指標後，得到

$$\mathbb{E}[(C_i^*)^2 \mathbf{1}_{\mathcal{E}}] \leq K(d + d^2) \mathbb{E}[H_R(U^{(i)}) \mathbf{1}_{\mathcal{E}^{(i)}}] \leq K_R(d + d^2) e^{-cd \log R}. \quad (6.4)$$

此處不假設全圖好事件與被刪行獨立。

Degree 的 Chernoff 界為

$$\mathbb{P}(D_i > Ld) \leq \exp\{-cLd \log(L/K)\}.$$

先選 L 控制此項，再選 R 使 (5.10)、(6.3)、(6.4) 的指數常數超過指定的 H 。對後兩式使用 Markov，最後讓 n 足夠大使 $K_{L,R} \sqrt{d} < \varepsilon d/2$ ，便得到結論。□

6.1 中心逆矩陣消去譜旋轉

先用真實社區的平均值作分析，令

$$K_U = \sqrt{n} \operatorname{diag}(n_a)^{-1} Z^\top W U,$$

$$K_i^0 = \sqrt{n} \operatorname{diag}(m_a)^{-1} Z_J^\top W^{(i)} f_t(U_J^{(i)}).$$

令 $Q_i^w = Z_J^\top (W^{(i)})^2 Z_J$ 。訓練母體基底為 $W^{(i)} Z_J (Q_i^w)^{-1/2} O$ 。若 $\eta_a = m_a^{-1} \sum_{j \in J: z_j = a} (w_j^{(i)})^2$ ，則其相應社區中心為

$$\operatorname{diag}\left(\sqrt{\eta_a / (m_a/n)}\right) O.$$

因此 $\sigma_{\min}(K_i^0) \geq c$ ，且 $\|U^{(i)} - f_t(U^{(i)})\|_F = O(d^{-1/2})$ ，因母體行 norm 小於截斷門檻。

在引理 6.1 所用的局部好事件上，(5.2)、 $\|G_i\|_{\text{op}} \leq K/d$ 和上述截斷誤差給

$$\|K_U O_i^\top - K_i^0\|_{\text{op}} = O(d^{-1/2}).$$

從而

$$\begin{aligned} q_i K_U^{-1} - r_i (K_i^0)^{-1} &= (q_i O_i^\top - r_i) (K_U O_i^\top)^{-1} \\ &\quad + r_i \{(K_U O_i^\top)^{-1} - (K_i^0)^{-1}\}. \end{aligned}$$

$\|r_i\| \leq RD_i = O_{L,R}(d)$ ，故第二項只有 $O_{L,R}(\sqrt{d})$ 。將真實社區中心換成初始聚類中心只增加 $o(1)$ 的矩陣誤差：誤分比例 $o(1)$ 與 $\|WU\|_F \leq \sqrt{k}$ 通過 Cauchy-Schwarz 即可控制社區平均值。

最後， $\|q_i\| \leq K_{L,R}d$ ，所以中心、degree 校正、社區比例以及 B 的一致估計，總共只增加 $o(d)$ 的 LLR 誤差。因此對任意固定 $\varepsilon, H > 0$ ，

$$\mathbb{P}\left(|\hat{L}_i^{ab} - \hat{L}_i^{\text{LOO},ab}| > \varepsilon d\right) \leq e^{-Hd} + O(n^{-r}). \quad (6.5)$$

結合 (4.11)，並讓固定 H 任意大，即證得 (1.7)。

7 Oracle Chernoff 指數與主要定理的完成

真實 LLR 的 Chernoff 函數是

$$\begin{aligned} J_{ab,n}(s) &= -\log \mathbb{E}_a e^{-sL_i^{ab}} \\ &= -\sum_{j \in J} \log\{p_{aj}^{1-s} p_{bj}^s + (1-p_{aj})^{1-s} (1-p_{bj})^s\}, \end{aligned} \quad (7.1)$$

其中 $p_{hj} = \rho_n C_{h,z_j}$ 。記 $J_{ab,n} = \max_s J_{ab,n}(s)$ 。對 $s \in [0, 1]$ 一致展開，每條邊的餘項為 $O(\rho_n^2)$ ；總餘項 $O(n\rho_n^2) = o(d)$ ，故

$$J_{ab,n} = dI_{ab} + o(d). \quad (7.2)$$

由 (1.7)，在 H_a 下

$$\begin{aligned} \mathbb{P}_a(\hat{L}_i^{ab} \leq 0) &\leq \mathbb{P}_a(L_i^{ab} \leq \varepsilon d) + \mathbb{P}_a(|\hat{L}_i^{ab} - L_i^{ab}| > \varepsilon d) \\ &\leq \exp\{-J_{ab,n} + s_* \varepsilon d\} + e^{-\omega(d)}. \end{aligned} \quad (7.3)$$

s_* 是精確 Chernoff 最優值；對 H_b 同理。令 $\varepsilon \downarrow 0$ ，得到算法風險上界的指數 I_{ab} 。

為使 oracle 下界亦自包含，定義傾斜測度

$$\frac{dQ_s}{dP_a} = \exp\{-sL_i^{ab} + J_{ab,n}(s)\}.$$

不同 profile 保證最優值 $s_* \in (0, 1)$ 。在 Q_{s_*} 下，各邊仍獨立，其成功概率為

$$r_j = \frac{p_{aj}^{1-s_*} p_{bj}^{s_*}}{p_{aj}^{1-s_*} p_{bj}^{s_*} + (1-p_{aj})^{1-s_*} (1-p_{bj})^{s_*}} = O(\rho_n).$$

一階最優條件給 $\mathbb{E}_{Q_{s_*}} L_i^{ab} = 0$ ，而 logit 對比有界給 $\text{Var}_{Q_{s_*}}(L_i^{ab}) = O(d)$ 。故存在固定 K ，使 $Q_{s_*}(|L_i^{ab}| \leq K\sqrt{d}) \geq c > 0$ 。等先驗 oracle Bayes risk 為

$$\begin{aligned} R_{\text{oracle},ab} &= \frac{1}{2} e^{-J_{ab,n}} \mathbb{E}_{Q_{s_*}} \min\{e^{s_* L_i^{ab}}, e^{-(1-s_*) L_i^{ab}}\} \\ &\geq c e^{-J_{ab,n} - K\sqrt{d}}. \end{aligned}$$

與 Chernoff 上界結合，即

$$R_{\text{oracle},ab} = e^{-dI_{ab} + o(d)}.$$

完整原始資料的 oracle 已是最優檢驗，任何由 $\mathcal{S}(A)$ 得到的判別都不能有更好的指數。與 (7.3) 合併，定理 1.1 得證。

8 為何 L^2 譜壓縮可以保留 LLR

SVD 的平方誤差目標與 likelihood 的對數權重，扮演的是不同角色：前者用來尋找一個低維座標系，後者用來在這個座標系中作判別。關鍵不是讓 SVD 本身計算對數，而是確認其保留的座標足以還原 LLR 所需要的觀測統計量。在滿秩 SBM 中，這些統計量就是一個節點連向各個社區的連邊數。

8.1 觀測到的 LLR 對連邊數是線性的

固定待分類節點 i ，令 $\mathcal{J}_i = \{1, \dots, n\} \setminus \{i\}$ ，並暫時把其餘節點的社區標籤視為已知。設

$$m_c = \#\{j \in \mathcal{J}_i : z_j = c\}, \quad N_{ic} = \sum_{j \in \mathcal{J}_i : z_j = c} A_{ij}.$$

記連接概率矩陣為 $B = (p_{ac})_{a,c=1}^k$ ，其中 $0 < p_{ac} < 1$ 。在候選假設 $z_i = a$ 下，節點 i 的觀測對數 likelihood 為

$$S_i(a) = \sum_{c=1}^k \{N_{ic} \log p_{ac} + (m_c - N_{ic}) \log(1 - p_{ac})\}.$$

因此，等先驗下比較 $z_i = a$ 與 $z_i = b$ 的 LLR 可以精確寫成

$$L_i^{ab} = S_i(a) - S_i(b) = N_i \ell^{ab} + \kappa_{ab}, \quad (8.1)$$

$$\ell_c^{ab} = \log \frac{p_{ac}(1 - p_{bc})}{p_{bc}(1 - p_{ac})}, \quad \kappa_{ab} = \sum_{c=1}^k m_c \log \frac{1 - p_{ac}}{1 - p_{bc}}.$$

此處 $N_i = (N_{i1}, \dots, N_{ik})$ 是行向量， ℓ^{ab} 是列向量。非等先驗只會增加一個對數先驗比常數。

LLR 對概率參數是非線性的，對觀測連邊數卻是線性的。因而保留 N_i ，就保留了全部 local LRT 分數；不必在壓縮時便把 $\log p_{ac}$ 算進去。

所謂的 $p \log p$ ，則出現在對這個隨機 LLR 取期望之後：

$$\mathbb{E}_a L_i^{ab} = \sum_{c=1}^k m_c \left[p_{ac} \log \frac{p_{ac}}{p_{bc}} + (1 - p_{ac}) \log \frac{1 - p_{ac}}{1 - p_{bc}} \right]. \quad (8.2)$$

這是兩個條件分布的 KL divergence。在 $p_{ac} = \rho_n C_{ac}$ 、 C 固定且所有元素為正的稀疏情形，式 (8.2) 等於

$$\sum_{c=1}^k m_c \left[p_{ac} \log \frac{p_{ac}}{p_{bc}} - p_{ac} + p_{bc} \right] + O(n \rho_n^2).$$

實際分類使用的是式 (8.1) 中隨機的 N_i ，而不是把它換成期望後的 KL divergence。

8.2 母體譜空間保留了哪些方向

令 $Z_{-i} \in \{0, 1\}^{(n-1) \times k}$ 為其餘節點的社區指示矩陣，並假設每一社區在訓練圖中均非空。記

$$a_i = (A_{ij})_{j \in \mathcal{J}_i}, \quad Q_i = Z_{-i}^\top Z_{-i} = \text{diag}(m_1, \dots, m_k).$$

則 $N_i = a_i Z_{-i}$ 。投影到全部 block-constant 向量所張成空間的正交投影矩陣是

$$\Pi_i = Z_{-i} Q_i^{-1} Z_{-i}^\top.$$

由 $\Pi_i Z_{-i} = Z_{-i}$ ，立刻得到兩個精確等式：

$$(a_i \Pi_i) Z_{-i} = N_i, \quad a_i \Pi_i (Z_{-i} \ell^{ab}) = a_i (Z_{-i} \ell^{ab}). \quad (8.3)$$

事實上， $a_i \Pi_i$ 在社區 c 的每一個位置都等於 N_{ic}/m_c 。它把同一社區內的連邊配置平均化，卻完整保留每個社區的連邊總數。被投影掉的向量滿足

$$a_i (I - \Pi_i) Z_{-i} = 0;$$

也就是每個社區內的總和均為零。式 (8.1) 對這些方向本來就不敏感。

為把這個空間與 SVD 聯繫起來，考慮代數上的 block 矩陣

$$P_{0,-i} = Z_{-i} B Z_{-i}^\top.$$

這裡保留其對角元素只是為了表示精確低秩結構，並不表示觀測圖含有自環；真正的無自環期望矩陣還要扣除相對角線。若 B 滿秩，則

$$\text{col}(P_{0,-i}) = \text{col}(Z_{-i}).$$

因此，母體信號矩陣的 k 維譜空間，恰好就是保留式 (8.3) 所需的空間。

8.3 對數沒有把 LRT 帶出這個空間

SBM 的特殊性在於：任意只依賴社區標籤的向量，都屬於 $\text{col}(Z_{-i})$ 。不論 h 是線性函數、對數函數或 logit 函數，只要

$$v_j = h(z_j),$$

就有 $v = Z_{-i}(h(1), \dots, h(k))^\top$ 。所以 LRT 的邊權向量

$$\left(\log \frac{p_{a,z_j}(1 - p_{b,z_j})}{p_{b,z_j}(1 - p_{a,z_j})} \right)_{j \in \mathcal{J}_i} = Z_{-i} \ell^{ab}$$

仍處於同一個 k 維空間。

等價地，將 logit 逐項作用於 $P_{0,-i}$ ，而非作矩陣函數運算，便有

$$\text{logit}_{\text{entry}}(P_{0,-i}) = Z_{-i} L Z_{-i}^\top, \quad L_{ac} = \log \frac{p_{ac}}{1 - p_{ac}}.$$

因而

$$\text{col}(\text{logit}_{\text{entry}}(P_{0,-i})) \subseteq \text{col}(Z_{-i}) = \text{col}(P_{0,-i})$$

在 B 滿秩時成立。對數改變的是這個空間中的係數，而不是產生了必須另外保存的新方向。一般低秩矩陣不具有此性質；對其元素取對數，可能增加秩並改變列空間。

8.4 可逆座標變換，以及 k -means 的差別

母體信號空間的任意正交基均可寫成

$$U_* = Z_{-i} H, \quad H = Q_i^{-1/2} O,$$

其中 O 為正交矩陣，故 H 可逆。節點 i 對此基底的投影特徵是

$$x_i = a_i U_* = N_i H.$$

所以

$$\boxed{N_i = x_i H^{-1}, \quad L_i^{ab} = x_i H^{-1} \ell^{ab} + \kappa_{ab}.} \quad (8.4)$$

SVD 不需要以 likelihood 為優化目標：只要找到這個完整的座標系，式 (8.4) 便能在壓縮後再施加正確的對數權重。

然而，在譜座標中直接使用歐氏距離分類，並不同於這個解碼後的 LRT。即使已經恢復了 N_i ，繼續用最近均值的平方距離規則，通常也不會產生正確的 likelihood 係數。

例如，考慮稀疏局部問題的 Poisson 形式，兩個候選社區的連邊數均值為

$$\lambda_a = t(4, 1, 1), \quad \lambda_b = t(1, 2, 1), \quad t > 0.$$

這兩個連接輪廓可來自對稱、滿秩、正元素的矩陣

$$C = \begin{pmatrix} 4 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 3 \end{pmatrix}$$

及等大小的訓練社區。對獨立 Poisson 連邊數，準確的 LLR 是

$$L_i^{ab} = N_{i1} \log 4 - N_{i2} \log 2 - 2t.$$

因此 likelihood 規則選擇 a 的條件為

$$2N_{i1} - N_{i2} > \frac{2t}{\log 2}.$$

但將 N_i 分配給歐氏距離較近的均值，得到的條件卻是

$$\|N_i - \lambda_a\|^2 < \|N_i - \lambda_b\|^2 \iff 3N_{i1} - N_{i2} > 6t.$$

兩者的權重與門檻均不同。這個例子只用 Poisson 形式展示判別幾何；Bernoulli SBM 的精確分數仍是式 (8.1)。

若改在 $x_i = N_i H$ 中使用平方距離，則相當於在 N_i 中使用由 $HH^\top$ 決定的二次型。這同樣不會自動產生所需的對數概率比。因而，譜特徵能保留 likelihood 信息，與 k -means 是否有效利用了這些信息，是兩個不同問題。

8.5 從母體恆等式到樣本譜信息的界線

以上母體投影的等式是精確線性代數結論，但不能將樣本矩陣的 rank- k 截斷 A_k 直接等同於 $A\Pi$ 。同樣地，只證明一個去噪矩陣在 Frobenius norm 下接近期望矩陣，還不足以推出 LRT 的錯誤指數不變。

對正則化矩陣 $M = WAW$ ，全圖 eigen-equation 提供的是另一個精確關係：

$$MU = U\Lambda \implies AWU = W^{-1}U\Lambda.$$

右側可以由原始 degree 和保留的譜信息計算，因此保存了對估計譜基底的逐節點連接投影。要由它還原 AZ ，還須估計社區中心、反解相應座標變換，並控制隨機權重、基底誤差及節點依賴。LOO 的作用正是拆開待分類節點連邊與訓練基底之間的依賴；保留 LRT 指數還需要大偏差尺度的誤差控制，不能只依賴均方一致性或中心極限定理。

滿秩也是上述解釋中的實質條件。若 B 的秩為 $r < k$ ，則母體譜空間可能嚴格小於 $\text{col}(Z_{-i})$ 。若只保留對 r 維母體基底 U_r 的投影與 degree，相同的線性解碼論證要求相關 LRT 係數滿足

$$Z_{-i}\ell^{ab} \in \text{span}\{\mathbf{1}, \text{col}(U_r)\}.$$

degree 增加的是常數方向，某些特殊連接輪廓下足以補上缺少的信息；一般情形則不能僅由低秩或 degree 的存在保證這個包含關係。這一點也說明，本節的核心是 SBM 的 block 結構與可逆座標表示，而不是所有 L^2 低秩近似都天然具有 likelihood 最優性。

9 結果的邊界與後續可研究問題

1. **錯誤指數與風險比**。本稿得到 $-\log R_{\text{spec}}/(-\log R_{\text{oracle}}) \rightarrow 1$ 。相對誤差 $R_{\text{spec}}/R_{\text{oracle}} \rightarrow 1$ 還涉及前因子和更精細的閾值誤差，本文沒有證明。
2. **社區判別與參數信息**。本稿的相對一致參數估計足以支撐局部分類指數。它不推出 B 的漸近有效估計，也不推出整個 SBM 參數實驗的無損壓縮。
3. **稀疏度與信號退化**。 $d \rightarrow \infty$ 用於譜子空間一致性及尾能量吸收； $d = o(\log n)$ 使 n^{-r} 的訓練失敗概率在速度 d 下可忽略。本稿不處理 $d = O(1)$ 、 $k \rightarrow \infty$ 、零概率，或 $C = C_n$ 的最小信號特徵值趨零的情況。
4. **秩不足**。若 $\text{rank}(C) < k$ ，信號空間不必容納所有 block-constant LLR 係數。Degree 可加入常數方向，某些比例 profile 的判別也只需 degree，但一般退化模型需要另行刻畫所需係數空間。
5. **去噪矩陣的含義**。對逐節點譜特徵反解後，可以構造秩至多 k 的行平滑矩陣

$$\tilde{A}_{\text{cal}} = \hat{N} \text{diag}(\hat{n}_c)^{-1} \hat{Z}^\top.$$

它滿足 $\tilde{A}_{\text{cal}}\hat{Z} = \hat{N}$ 、 $\tilde{A}_{\text{cal}}\mathbf{1}_n = D$ 。這是保留逐節點連接波動的校準重建；不必對稱，也不必逐項落在 $[0, 1]$ 。證明使用其線性分數意義。直接把所有同類節點替換為同一行的 $\hat{Z}\hat{B}\hat{Z}^\top$ ，則沒有保留此處使用的逐節點波動。

編譯說明

本文件是單一、自包含的 .tex 原始碼，參考文獻在檔案內。使用含 xeCJK 的 TeX Live / MiKTeX，以 XeLaTeX 編譯兩次：

```
xelatex sbm_spectral_lrt_20261009.tex
xelatex sbm_spectral_lrt_20261009.tex
```

字體優先使用 Noto Serif CJK TC；若未安裝，原始碼會使用 TeX Live 常見的 Fandol 字體。數學排版、目錄與交叉引用均由 LaTeX 產生。

參考文獻

- [1] Can M. Le, Elizaveta Levina, and Roman Vershynin. *Concentration and regularization of random graphs*. arXiv:1506.00669v2, 2016. 本稿使用 Theorem 2.1 的正則化集中結果。
<https://arxiv.org/abs/1506.00669>.